

INFORME CONSULTAS PROYECTO 2.

LABORATORIO BIOSEÑALES

Isabela Grajales Montoya
Liliam Zamanta Estupiñán Santos
Daniel Felipe Tamayo Cortes

1000100161
1014306103
1214747121

1. De los artículos, para cada artículo hacer un diagrama de flujo de las metodologías usadas en los artículos y explicar en sus palabras las metodologías desarrolladas.

Prediction of atrial fibrillation from at-home single-lead ECG signals without arrhythmias



Un diagnóstico temprano de fibrilación articular (FA) puede reducir el riesgo de accidente cerebrovascular, insuficiencia cardíaca, entre otras afecciones. Para este fin, fue desarrollado un modelo para cuantificar el riesgo de FA a corto plazo con muestras tomadas en un periodo de dos semanas y su aplicación puede brindar una estrategia digital para mejorar la captura diagnóstica de la FA mediante de la estratificación del riesgo de los individuos, lo cual conduce potencialmente a diagnóstico temprano y por tanto un inicio más rápido del tratamiento.

Metodología

Características de los individuos incluidos en este estudio

Para el control del ritmo cardíaco, a los participantes se les suministró un parche adhesivo para la piel, resistente al agua, utilizado para la monitorización ambulatoria de ECG de una sola derivación hasta por 14 días.

La señal de ECG capturada por el parche fue ingresada en el modelo, junto con la anotación en el informe clínico, que incluía la detección de arritmias, la presencia de latidos ectópicos y la frecuencia cardíaca estimada.

El evento de interés del estudio fue la fibrilación auricular (FA), definida como una arritmia persistente de más de 30 segundos. Los pacientes se clasificaron como positivos para FA si presentaban al menos un episodio durante el monitoreo de 2 semanas.

Los datos utilizados para entrenar el modelo se obtuvieron entre enero de 2019 y mayo de 2022, excluyendo grabaciones con FA persistente. Para garantizar la precisión en diferentes grupos de edad, se entrenaron submodelos específicos con grabaciones que incluían al menos un episodio de FA.

El estudio analizó un total de 459.889 grabaciones provenientes de 446.900 individuos. Las grabaciones se distribuyeron en tres cohortes: entrenamiento, calibración y prueba.

Modelo para la predicción de la FA

El modelo utiliza intervalos de ECG de una sola derivación, con duraciones de entre 10 minutos y 24 horas, sin presencia de FA. La estructura del modelo se divide en etapas según la duración de la entrada.

En la primera etapa, se extraen características de intervalos de 10 minutos, tales como:

- Métricas de variabilidad de la frecuencia cardíaca (VFC), excluyendo latidos ectópicos.
- Métricas de otros ritmos anormales, como taquicardia supraventricular.

Se empleó un módulo de aprendizaje profundo (DLA) para descubrir características relevantes y compactas del ECG.

El modelo se entrenó con diferentes configuraciones de entrada: datos demográficos, combinaciones de VFC, recuento de latidos ectópicos, y características extraídas manualmente y por el DLA.

En la segunda etapa, las características de múltiples intervalos de 10 minutos se integraron en un módulo adicional de aprendizaje profundo que analiza la señal a mayor escala para estimar el riesgo de FA.

Funciones de aprendizaje de representación: El intervalo de 10 minutos se determinó como un tamaño adecuado para entrenar el modelo, evitando la complejidad excesiva en secuencias largas, que son difíciles de procesar para redes neuronales recurrentes (RNN).

El módulo DLA se entrenó para extraer características predictivas de episodios futuros de FA a partir de intervalos sin FA. Cada intervalo de 10 minutos fue codificado en 128 características esenciales. Una vez entrenado, los pesos del DLA no se actualizaron en la segunda fase.

Procesamiento de ECG largo

Para la evaluación final, se utilizaron señales de hasta 24 horas. La secuencia generada en la primera etapa fue procesada por un módulo LSTM para interpretar la probabilidad de riesgo.

Se calibró el modelo con una cohorte de calibración por grupo de edad para ajustar las puntuaciones de riesgo.

Limpieza, procesamiento y normalización

Dado que las características (VFC, ritmo ectópico, edad y género) tienen diferentes escalas, se realizaron procesos de normalización y transformación para una mejor integración en el modelo:

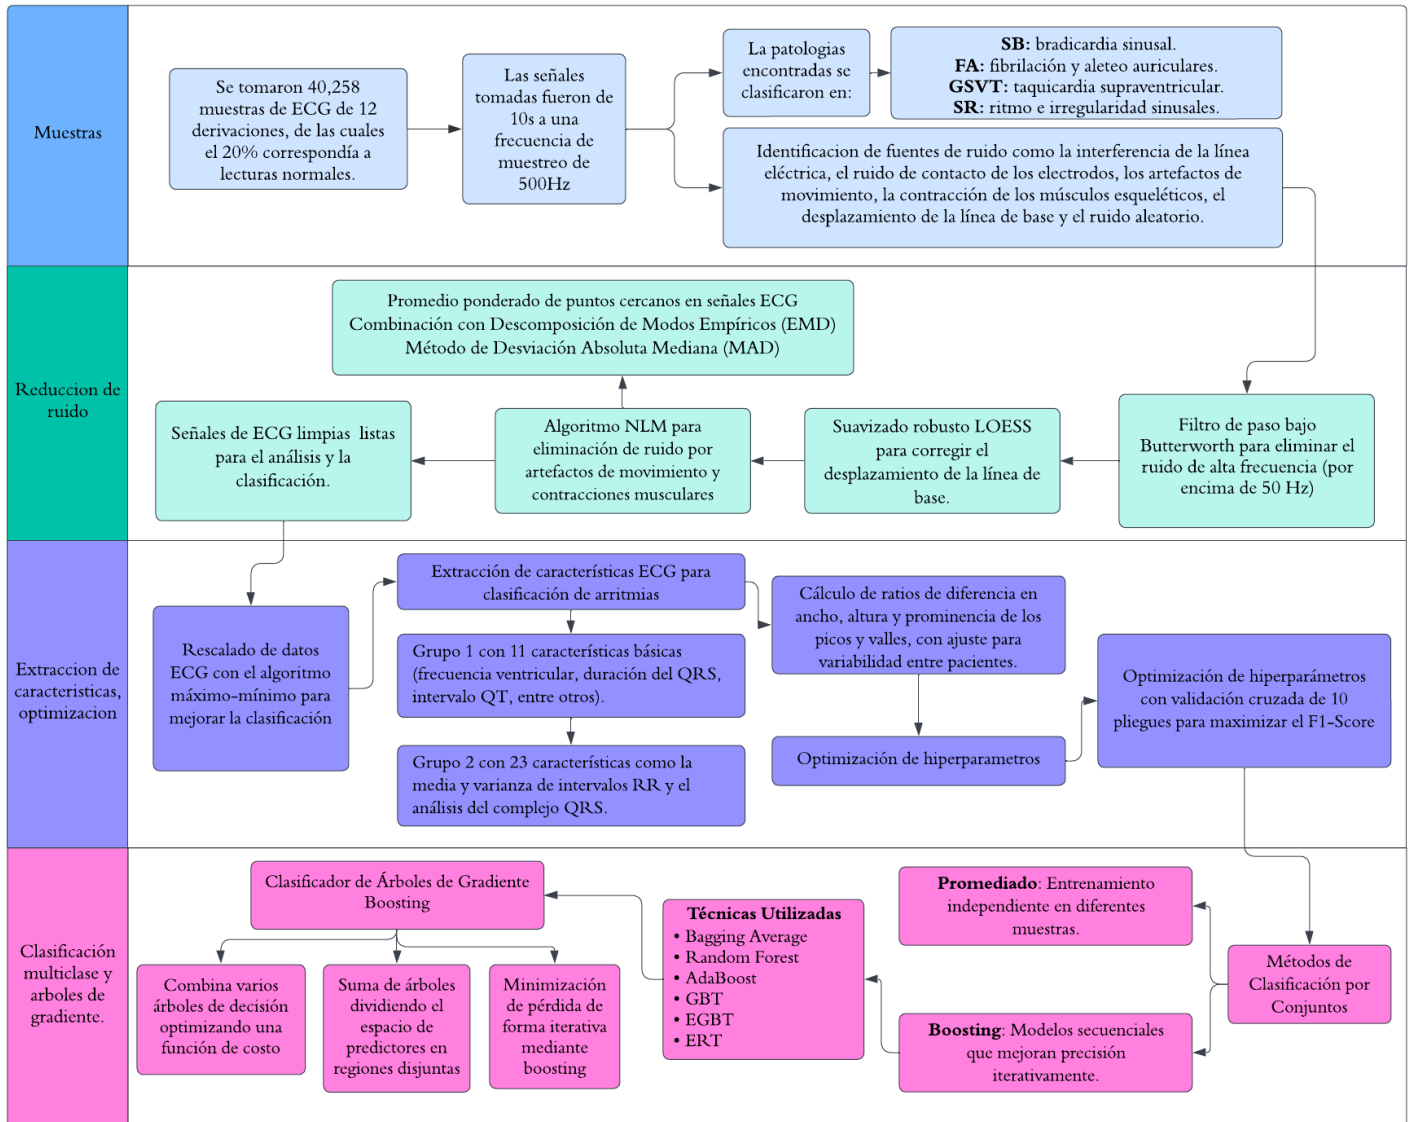
- Transformación exponencial para variables de ritmo.
- Eliminación de desplazamientos y escalado.
- Transformación Box-Cox para una distribución cercana a la normal.

Se excluyeron señales de baja calidad o con artefactos.

Las grabaciones se descartaron si tenían una frecuencia cardíaca promedio muy baja o pocos picos R detectados.

El modelo fue evaluado utilizando métricas de AUC y precisión promedio, considerando intervalos de confianza estimados mediante prueba bootstrap.

Optimal Multi-Stage Arrhythmia Classification Approach



La arritmia es un trastorno que afecta la frecuencia o el ritmo del latido cardíaco, y un diagnóstico temprano es crucial para iniciar un tratamiento eficaz. En este estudio, se optimizó un esquema de clasificación de arritmias en múltiples etapas utilizando un electrocardiograma (ECG) de 12 derivaciones, alcanzando un nivel de precisión comparable al de cardiólogos profesionales. Este enfoque incluyó un proceso de reducción de ruido en tres pasos, un novedoso método de extracción de características y un modelo de clasificación con hiperparámetros ajustados de manera óptima.

Metodología

Se llevó a cabo un estudio exhaustivo que comparó miles de algoritmos de clasificación, entrenados en un amplio conjunto de datos patentado y etiquetado por expertos, que contenía ECG de 12 derivaciones de 40,258 pacientes. Los resultados indicaron que el enfoque óptimo incluyó un filtro pasa-bajos, un suavizado robusto LOESS, un

suavizado de medias no locales (NLM) y un método patentado de extracción de características basado en percentiles de la distribución empírica de las proporciones de longitudes de intervalos y las magnitudes de picos y valles. El clasificador más eficaz fue un árbol de refuerzo de gradiente extremo.

Población estudiada

Se utilizaron 40,258 ECG de 12 derivaciones, de los cuales 22,599 correspondían a hombres y 17,659 a mujeres. Los participantes fueron seleccionados de manera aleatoria en el Hospital Popular de Shaoxing y el Primer Hospital de Ningbo de la Universidad de Zhejiang, entre 2013 y 2018. El conjunto de datos contenía un 20% de lecturas de ritmo sinusal (SR) normales y un 80% de lecturas anormales. Los grupos de edad con mayor prevalencia de arritmias fueron de 51-60 años (19.8%), 61-70 años (24%) y 71-80 años (17.3%).

Proceso de muestreo

Los datos de ECG de cada paciente se recogieron durante 10 segundos, a una frecuencia de muestreo de 500 Hz, y fueron etiquetados por médicos supervisados por cardiólogos. Las etiquetas incluyeron 11 tipos de ritmo y 67 hallazgos cardíacos adicionales, como PVC, RBBB, LBBB y APC. Debido a la rareza de algunos ritmos, varios casos raros se agruparon en categorías más amplias de arritmias.

Clasificación de patologías

Se clasificaron los ritmos en 4 grupos principales: **SB** (bradicardia sinusal), **FA** (fibrilación y aleteo auricular), **GSVT** (taquicardias supraventriculares) y **SR** (ritmo sinusal), junto con un grupo adicional de "arritmias de nivel superior" para sujetos sin las condiciones anteriores. Este enfoque permite diferenciar con mayor precisión entre los grupos FA y GSVT, y separar la irregularidad sinusal del ritmo sinusal mediante la variación en el intervalo RR.

Reducción de ruido

Las principales fuentes de ruido identificadas en las señales ECG incluyeron la interferencia de la línea eléctrica, el ruido de contacto de los electrodos, artefactos de movimiento, contracciones musculares, desplazamiento de la línea de base y ruido aleatorio. El desplazamiento de la línea de base es causado principalmente por la respiración, con una frecuencia menor a 0.5 Hz, mientras que la interferencia eléctrica se encuentra entre 50 y 60 Hz.

Para mitigar estos ruidos, implementaron un esquema de filtrado en tres pasos:

1. **Filtro pasa-bajos Butterworth:** Para eliminar el ruido de alta frecuencia (superior a 50 Hz).
2. **Suavizado robusto LOESS:** Para corregir el desplazamiento de la línea de base.
3. **Medias no locales (NLM):** Para reducir otros ruidos como artefactos de movimiento y contracciones musculares.

Explicación del algoritmo NLM

El algoritmo de medias no locales (NLM) se utilizó para eliminar el ruido, combinándolo con la descomposición de modos empíricos (EMD). Este algoritmo reconstruye la señal real en cada punto de tiempo a través del promedio ponderado de todos los puntos cercanos dentro de un rango predefinido. Los pesos se determinan según la similitud entre los puntos.

Se empleó el método de desviación absoluta mediana (MAD) para estimar la variabilidad del ruido, utilizando un kernel gaussiano como función de peso para suavizar la señal. Los puntos de la señal se promediaron dentro de una ventana de tamaño 10, ajustando el parámetro de suavidad λ a 1.5 veces la desviación estándar del ruido estimado.

Después de pasar por los tres filtros de eliminación de ruido, se eliminó el ruido de alta frecuencia y las desviaciones de la línea de base, obteniendo datos de ECG más limpios y preparados para su análisis y clasificación.

Extracción de características

Se utilizaron modelos de redes neuronales para la clasificación de arritmias, empleando transformaciones secuenciales de datos brutos como características, aunque su entrenamiento requiere grandes volúmenes de datos y tiempo. Métodos comunes de extracción de características incluyen magnitudes y distancias entre picos en las principales ondas del ECG (P, Q, T, QRS). Sin embargo, estos enfoques no permiten clasificar con precisión ciertos tipos de arritmias, como AFIB y AFL. Métodos como Wavelet o Fourier pierden información del dominio temporal, y las diferencias en morfología de onda, género, edad y raza complican aún más el proceso.

Para mitigar estas dificultades, los datos fueron rescalados con el algoritmo máximo-mínimo. Se propuso un método que analiza 11 escenarios diferentes de extracción de características, que incluyen variables como edad, género y medidas de los intervalos RR.

Grupos de Características:

- Grupo 1: 11 características básicas (frecuencia ventricular, duración del QRS, intervalo QT, entre otros).
- Grupo 2: 23 características adicionales, como la media y varianza de intervalos RR y el análisis del complejo QRS.

Se calcularon ratios de diferencia en ancho, altura y prominencia de los picos y valles en combinaciones específicas, gestionando la variabilidad entre pacientes con tablas de frecuencia empírica.

Búsqueda en Rejilla para Hiperparámetros

Se llevó a cabo una búsqueda exhaustiva de hiperparámetros utilizando validación cruzada de 10 pliegues. El objetivo fue optimizar el F1-Score promedio, seleccionando los valores más adecuados para los algoritmos de clasificación implementados en scikit-learn.

Métodos de Clasificación por Conjuntos

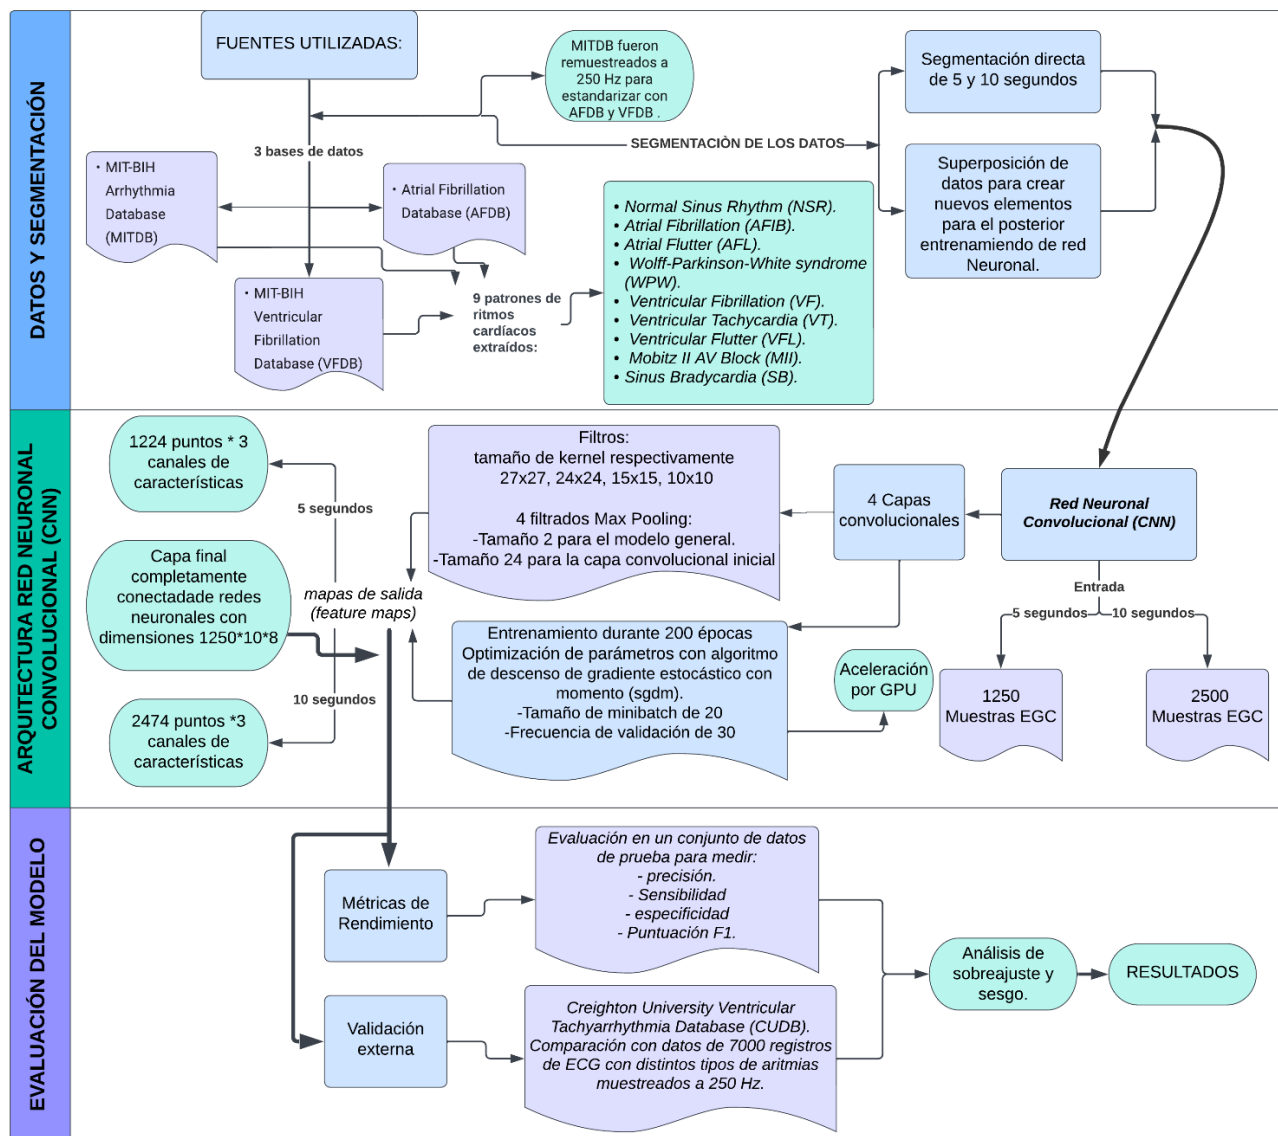
Para mejorar la precisión de la clasificación, se emplearon métodos de aprendizaje por conjuntos como el promediado y el boosting. El promediado entrena clasificadores de manera independiente en diferentes muestras, mientras que el boosting construye modelos secuenciales, mejorando la precisión en cada iteración al enfocar el entrenamiento en los ejemplos mal clasificados.

Se utilizaron técnicas como Bagging Average, Random Forest, AdaBoost, GBT, EGBT y ERT, evaluando 98 combinaciones de clasificadores con estrategias multi-clase como One Vs Rest y One Vs One. La validación cruzada permitió determinar los mejores hiperparámetros que lograron el mayor F1-Score ponderado.

Clasificador de Árboles de Gradiente Boosting

Este clasificador combina varios árboles de decisión, optimizando una función de costo para mejorar la clasificación. Se basa en la suma de árboles que dividen el espacio de predictores en regiones disjuntas. El objetivo es minimizar una función de pérdida de forma iterativa, aproximando el resultado mediante un proceso de boosting.

An Arrhythmia classification approach via deep learning using single-lead ECG without QRS wave detection



El artículo parte de la selección de los datos de 3 bases de datos distintas, MIT-BIH Arrhythmia Database (MITDB), Atrial Fibrillation Database (AFDB) y MIT-BIH Ventricular Fibrillation Database (VFDB), utilizando el software Package (WFDB) de PhysioNet, todos ellos provenientes de estudios ECG de un solo canal, de los

cuales se tomaron 9 clasificaciones de ritmos cardíacos. Estandarizaron la frecuencia de muestreo de todos los datos a 250Hz.

Posteriormente, extrajeron segmentos de 5 y 10 segundos de los registros utilizando un método de "overlap sampling" para crear nuevos ejemplos a partir de estos segmentos y así aumentar el número de muestras disponibles para el entrenamiento.

La red neuronal convolucional (CNN) fue diseñada con varias capas convolucionales y capas de "max pooling" para la extracción de características. El modelo fue entrenado utilizando el algoritmo de descenso de gradiente estocástico con momento (sgdm), con un tamaño de minibatch de 20 y una frecuencia de validación de 30, es decir, se analizaron 2 muestras a la vez y cada 30 se reajustaban parámetros. El entrenamiento se llevó a cabo durante 200 épocas con aceleración por GPU para mejorar la eficiencia del proceso. El resultado de este proceso fue una capa final completamente conectada de dimensiones $1250 \times 10 \times 8$ que realizará la clasificación.

Para evaluar el rendimiento del modelo, utilizaron un conjunto de datos de prueba que incluía registros de ECG no utilizados, para después aplicar métricas de precisión, sensibilidad y especificidad. Finalmente, realizaron una prueba externa utilizando la Creighton University Ventricular Tachyarrhythmia Database (CUIDB), para comparar con datos del mundo real. Los resultados que obtuvieron mostraron altos niveles de precisión y sensibilidad en la clasificación de los diferentes ritmos cardíacos.

2. Consultar que significado y utilidad del biespectro

Por definición, el biespectro es la transformada de Fourier de dos dimensiones de las estadísticas de tercer orden (estadísticas de orden superior HOS). Provee información de la generación de armónicas producidas por acoplamientos de pares de frecuencias. Puede proporcionar información sobre las propiedades de tercer orden de la señal [2].

El bispectro sólo proporciona información en los casos en que el proceso aleatorio tiene una distribución sesgada. En un número significativo de problemas físicos, los sistemas son simétricos y producen señales de salida no sesgadas. En estas circunstancias, el bispectro es una medida no informativa [3].

El biespectro es una función de dos variables de frecuencia, f_1 y f_2 , y mientras que el espectro de potencia incluye la contribución de cada componente de frecuencia individual de forma independiente, el biespectro analiza las interacciones de frecuencia entre los componentes de frecuencia en f_1 , f_2 y f_1+f_2 [3].

Utilidad en el procesamiento de imágenes con aplicación a la restauración o reconstrucción de estas, como es el caso de reconstrucción de imágenes provenientes de telescopios. También es útil en la identificación de un sistema lineal por ruido no-gaussiano blanco mediante el uso de correlaciones de orden superior.

Es útil para detectar y caracterizar no linealidades en señales y sistemas, por lo que es usado en el procesamiento digital de señales [1]. Útil para analizar sistemas con no linealidades asimétricas.

El biespectro se puede implementar con varios tipos de señales como lo son:

- Análisis del electroencefalograma (EEG)
- Análisis de ECG y VFC (variabilidad de ritmo cardíaco)
- Análisis del electromiograma de superficie (sEMG)

- Análisis de otras bioseñales: ruidos pulmonares, ruidos cardíacos, ruidos intestinales y potenciales evocados somatosensoriales (Es el estudio de la vía somatosensorial, vía encargada de transmitir información táctil, vibratoria y propioceptiva.)
- Análisis de bioseñales 2D [4].

Del artículo:

A partir del análisis espectral de potencia, descubrimos que hay muchas frecuencias más altas que la frecuencia de pulso y sus armónicos, que están recibiendo una potencia significativa. Dado que el espectro de potencia es un análisis lineal, no puede brindar una mayor comprensión del papel de estas frecuencias o las relaciones dinámicas entre ellas. Para esto, tenemos que realizar un análisis espectral de orden superior, utilizando cálculos de biespectros y bicoherencia. La estimación biespectral extrae el grado de acoplamiento de fase cuadrático entre los componentes de frecuencia individuales de la señal. Para calcular el biespectro, los datos se dividen en N segmentos y se calculan sus transformadas de Fourier.

$$b(f_1, f_2) = \sum_{j=1}^N X_j(f_1)X_j(f_2)X_j^*(f_1 + f_2)$$

Donde:

N es el número de segmentos, cada uno con una longitud de 8192, en nuestros cálculos. $X(f_1)$ y $X(f_2)$ son la transformada de Fourier de tiempo discreto calculada como transformada de Fourier discreta (DFT) utilizando el algoritmo FFT. El biespectro se normaliza entonces de modo que tenga una magnitud en el rango (0,1), para obtener la bicoherencia correspondiente.

Referencias

- [1] Mariño, W. A. (2016). BIESPECTRO. <https://www.academia.edu/28141592/BIESPECTRO>
- [2] Análisis de sistemas en el dominio del tiempo. (s. f.). Universidad de Oviedo. Recuperado 24 de septiembre de 2024, de <http://isa.uniovi.es/docencia/raeutig/tema3.pdf>
- [3] Collis, W., White, P., & Hammond, J. (1998). HIGHER-ORDER SPECTRA: THE BISPECTRUM AND TRISPECTRUM. *Mechanical Systems and Signal Processing*, 12(3), 375–394.
<https://doi.org/10.1006/mssp.1997.0145>
- [4] Chua, K. C., Chandran, V., Acharya, U. R., & Lim, C. M. (2010). Application of higher order statistics/spectra in biomedical signals—A review. *Medical Engineering & Physics*, 32(7), 679–689.
<https://doi.org/10.1016/j.medengphy.2010.04.009>

[5] Yamini Kotriwara, Sneha Kachharaa, K. P. Harikrishnanb, G. Ambikaa,c,*}, “Higher order spectral analysis of ECG signals,” Indian Institute of Science Education and Research (IISER) Pune, 411008, Indi, Sep. 2018.

<https://arxiv.org/pdf/1809.08451>