

## Informe proyecto 4 Bioseñales: Clasificación de señales ECG

Isabela Grajales Montoya	1000100161
Liliam Zamanta Estupiñán Santos	1014306103
Daniel Felipe Tamayo Cortes	1214747121

### 1. Revisión artículo: “**Optimal Multi-Stage Arrhythmia Classification Approach**” [1]

Los modelos de redes neuronales se han utilizado para la clasificación de arritmias y estos modelos trabajan procesando los datos crudos de ECG a través de transformaciones secuenciales para extraer características que luego se alimentan a un clasificador. Sin embargo, entrenar estos modelos puede ser complejo y requiere grandes cantidades de datos y tiempo de computación.

Las características como las magnitudes de los picos, duración, distancias entre picos y variabilidad en las ondas P, Q, T y el complejo QRS no siempre ofrecen una clasificación precisa, especialmente en arritmias donde estas ondas están distorsionadas o ausentes. Además, se enfrenta el desafío de las variaciones en la morfología de las ondas ECG entre individuos por diferencias en género, edad y raza.

En el artículo se realizó un proceso de extracción, primero se realizó un preprocesamiento para estandarizar la escala de amplitud, se utiliza un algoritmo de normalización basado en el valor máximo-mínimo. Después se tomaron las características básicas que incluye la tasa ventricular, la tasa auricular, la duración del QRS, el intervalo QT, entre otras y características avanzadas, como la media y varianza de los intervalos RR, así como la altura, el ancho y la prominencia de los picos del complejo QRS y otros picos no QRS.

Finalmente se calculó la prominencia de un pico o valle, para evaluar cómo se destaca en altura y su relación con los picos o valles vecinos. Esto se mide como la distancia vertical desde el punto máximo (o mínimo) hasta la línea de contorno más baja [1]. Las características se dividieron en 11 diferentes grupos donde los que más resaltan son:

- ✓ Grupo 1: Características básicas como la tasa ventricular y auricular, duración del QRS, intervalo QT, eje R, eje T, etc.
- ✓ Grupo 2: Características más avanzadas como la media y varianza de los intervalos RR, recuento de intervalos RR, prominencia de los picos, media y varianza de altura, ancho y prominencia del complejo QRS.
- ✓ Grupo 3: Las características de los anteriores grupos, pero enfocadas en la derivación 2
- ✓ Grupo 4: Las características de los anteriores grupos, pero enfocadas en las demás derivaciones.
- ✓ Grupo 6: Características detalladas para un canal ECG específico (Derivación 2), que incluye un conjunto de frecuencias de altura, ancho, prominencia, y ubicación de los picos y valles, con un total de 3,302 características.

Se utilizó una distribución empírica de frecuencias para las ratios entre las diferencias de ancho, altura y prominencia de los picos, lo que ayuda a representar las variaciones entre pacientes y facilita la clasificación.

### Discusión

Cuando ciertas formas de onda desaparecen o se distorsionan debido a enfermedades, el proceso de extracción de características enfrenta desafíos significativos. Por ejemplo, en condiciones como la fibrilación auricular (FA) o el aleteo auricular (AFL), las ondas P normales pueden reemplazarse por ondas irregulares y de menor amplitud, conocidas como ondas de fibrilación o aleteo. Estas ondas no siguen la relación típica con los

complejos QRS, complicando su detección y clasificación. Por esto se entrenan algoritmos de aprendizaje con grandes conjuntos de datos que contienen tanto ejemplos normales como patológicos. Estos algoritmos aprenden las características específicas de ondas anómalas (como amplitud, frecuencia y patrón irregular) y las utilizan para clasificar ritmos. Según Victoria y colaboradores en el artículo Extracción de características de ECG basadas en transformaciones no lineales y wavelets el proceso de extracción de características tiene un gran impacto a la hora de clasificar las señales para identificar las diferentes patologías, además recomiendan el uso combinado de métodos estadísticos avanzados con técnicas de extracción [2].

## 2. Base de datos.

La base de datos seleccionada fue la obtenida en el proyecto 3. Esta elección se hizo debido a que al realizar pruebas estadísticas no paramétricas tanto en el conjunto de datos filtrado por los autores como los filtrados en el proyecto 3, se obtuvo por medio de la prueba de U Mann Whitney que los datos usados en el proyecto 2 no se encontraba una diferencia significativa entre los grupos AFIB y SB, mientras que en los datos del proyecto 3 por medio de la misma prueba se obtuvo que existe una diferencia significativa entre los grupos AFIB y SB, por lo que es posible diferenciar de mejor manera ambas patologías y esto favorece los análisis que se realizarán en este proyecto puesto que se pretenden determinar características diferenciales entre estas enfermedades.

## 3. Minitutorial Neurokit2.

Ver archivo Adjunto titulado Minitutorial\_Neurokit.pdf

## 4. Aplicación tutorial.

Se encuentra aplicado en el código adjunto.

## 5. Conjunto de características seleccionado.

### Características:

El enfoque de extracción de características realizado en el artículo de referencia en la derivación II del ECG incluyó:

- **Magnitudes y longitudes de picos y valles:** Se evaluaron las características relacionadas con la altura y la longitud de los picos y valles en la señal del ECG con el fin de identificar patrones específicos en los ritmos cardíacos.
- **Características distribucionales:** Se analizaron las características distribucionales de las transformaciones de los picos y valles.
- **Atributos de onda y duración temporal:** Se extrajeron características que revelan la relación entre los atributos de las ondas (como la amplitud y el tiempo) y la duración.
- **Frecuencia empírica:** Para cada par de picos o valles, se evaluó los percentiles de la distribución empírica de los cocientes de las longitudes de los intervalos y las magnitudes de los picos y los valles.

Así, fue posible distinguir las siguientes características puntuales a extraer:

### 1. Frecuencia cardíaca Media.

Dado que las condiciones patológicas a evaluar vienen determinadas por ritmos cardíacos distintos, la frecuencia cardíaca es una variable de interés a evaluar como característica.

### 2. Desviación estándar de la varianza de la frecuencia cardiaca (HRV)

HRV-SD1: Desviación estándar perpendicular a la línea de identidad. Es un índice de las fluctuaciones a corto plazo del intervalo RR, es decir, la variabilidad entre latidos [3].

### 3. Inverso de la longitud media de los segmentos de aceleración/deceleración (IALS).

Se utiliza para cuantificar la dinámica de variabilidad de la frecuencia cardíaca (HRV) [4].

Altura de los picos en las ondas: La onda P representa la despolarización auricular y alteraciones en su altura pueden indicar hipertrofia auricular o cambios en la conducción eléctrica. El complejo QRS, que representa la despolarización ventricular, muestra que cambios en la altura de las ondas Q, R o S pueden indicar hipertrofia ventricular, infarto de miocardio o trastornos de conducción. La onda T, que representa la repolarización ventricular, puede reflejar isquemia miocárdica, desequilibrios electrolíticos o efectos de medicamentos si presenta alteraciones en su altura [5].

#### 4. Altura Onda P

#### 5. Altura Onda R

#### 6. Altura Onda T


Duración (ancho) de los intervalos entre picos: El análisis de la duración entre los pares de picos PR, QT, QRS puede revelar problemas en la conducción eléctrica del corazón, la sincronización de las contracciones cardíacas y la eficiencia del ciclo cardíaco, lo que es esencial para el diagnóstico y el tratamiento de diversas enfermedades cardíacas, por lo cual, podrían ser diferenciadores patológicos al presentar patrones entre sujetos [6].

#### 7. Duración intervalo PR

#### 8. Duración intervalo QT

#### 9. Duración del complejo QRS.

En el artículo de referencia, hacen uso, entre otras, de las siguientes características empleando la derivación 2 (grupos 2 3 y 6), las cuáles dan cuenta de las relaciones en magnitud de los picos presentes en las ondas de ECG.



*Ilustración 1. "Example of ECG feature points, onset points and offset points." Puntos de onset y offset de los picos y valles de la señal ecg ideal según la literatura. [7]*

#### 10. Prominencia del complejo QRS respecto a los valles.

#### 11. Media de los intervalos RR.

#### 12. Varianza de los intervalos RR

Las características de picos globales y locales fueron seleccionadas dado que la librería implementada (Neurokit2) permite analizar la dinámica de la señal en sus picos prominentes (P, R, T) y en sus cambios locales, con lo cual

se pretende identificar posibles variaciones propias de cada patología (siendo la hipótesis que en AFIB se presentarán más de estos eventos que en SB).

**13. Número de picos globales.**

**14. Número de picos locales.**

**15. Frecuencia de máxima potencia**




Ilustración 2. “Main methods of calculating ECG rate”. Variación del ritmo cardíaco según el ancho de las señales [8].

#### Métricas Utilizadas en el Artículo

- ✓ Coeficiente de Entropía Muestral (CoSEn): Una medida de la complejidad y regularidad de una serie temporal, evaluando la predictibilidad de las fluctuaciones en una señal [9].
- ✓ Coeficiente de Varianza (CV).
- ✓ Raíz Cuadrada de las Diferencias Sucesivas (RMSSD): Mide las diferencias cuadráticas medias sucesivas entre intervalos RR adyacentes [10].
- ✓ Desviación Absoluta Mediana (MAD): Medida de la dispersión de una serie de datos.

#### 6. Dataframe:

Como resultado de la etapa de extracción de características, se obtuvo el siguiente dataframe (Ilustración 3):

	Registro	Patología	fMP	prominences	rr_mean	Crr_variance	Global_peaks	Local_peaks	P_peaks	R_peaks	T_peaks
0	MUSE_20180113_171327_27000	AFIB	3.0	0.923112	0.646143	0.002185	34	285	-0.080244	0.840130	0.058563
1	MUSE_20180114_075026_69000	AFIB	1.5	0.465798	0.619733	0.007965	31	242	-0.028398	0.362396	0.005981
2	MUSE_20180113_133901_16000	AFIB	1.5	0.819546	0.712615	0.006315	31	243	0.049367	0.717453	0.024242
3	MUSE_20180116_123940_90000	AFIB	3.5	0.735594	0.592667	0.019470	34	221	-0.019859	0.588566	0.032927
4	MUSE_20180114_075003_61000	AFIB	5.5	0.763286	0.399130	0.003212	33	213	-0.020224	0.489058	-0.058913
...	...	...	...	...	...	...	...	...	...	...	...
5174	MUSE_20180113_123024_89000	SB	1.0	0.956790	1.032667	0.000257	10	261	-0.014777	0.853567	0.129493
5175	MUSE_20180113_071521_20000	SB	0.5	0.643426	1.014667	0.006012	11	256	-0.029342	0.400500	0.116461
5176	MUSE_20180118_121651_25000	SB	1.0	0.818370	1.038667	0.001201	11	241	-0.010577	0.502661	0.206977
5177	MUSE_20180116_122935_97000	SB	1.0	0.719672	1.003333	0.004793	11	239	0.137091	0.410930	0.367047
5178	MUSE_20180113_182022_25000	SB	1.0	0.826291	1.023333	0.000110	10	356	-0.024001	0.677981	0.240235

5179 rows × 11 columns

Ilustración 3. Dataframe con las características extraídas a la base de datos, donde: fMP – Frecuencia Máxima Potencia, Prominences – Prominencias del complejo QRS respecto a los valles de cada señal, rr\_mean – Media de cada señal entre picos RR,

*Crr\_variance* – Varianza del tiempo entre picos RR, *Global\_peaks* – Sumatoria de los picos P, Q y R detectados, *Local\_peaks* – picos locales detectados por las funciones de Neurokit2, *P,R,T\_peaks* – valores medios de los picos respectivos.

De los 5669 sujetos presentes en la BD, fue posible extraer características a 5179 de ellos, siendo a su vez solo **9 de las 15 las características propuestas las extraídas** (Ilustración 3), incluida la fMP. Esto se debió a varios motivos. Aunque la BD utilizada fue preprocesada y filtrada en el proyecto anterior, garantizando la inexistencia de datos en cero, valores inválidos o NaN, y disminuyendo considerablemente los valores atípicos y la dispersión de los datos, al realizar el procesamiento y análisis empleando las funciones ecg de Neurokit2, se presentaron errores internos en las funciones de la librería, que fueron identificados con varias causas.


Se identificó la generación de valores NaN y divisiones en cero en varios puntos de la iteración, de estos errores logró identificarse que las características que dependen de la detección de picos o valles están limitadas, pues, para cada señal no es seguro que sean detectados todos sus picos y distinguidos los valles propios del comportamiento clásico de una onda ecg de derivación II, por lo que, los vectores generados presentaban diferentes dimensiones o valores nulos, con lo cual calcular intervalos temporales, anchos o magnitudes específicas no fue posible en todos los casos.

```
Iteración # 5495
Error al procesar la señal ECG 5495: cannot convert float NaN to integer
Iteración # 5496
/usr/local/lib/python3.10/dist-packages/neurokit2/signal/signal_period.py:84: NeuroKitWarning: Too few peaks detected to compute the rate. Returning empty vector.
warn(

[323] q_peaks
array([ nan,  nan,  nan,  nan,  nan,  nan,  nan, 2334.,  nan,
        nan, 3316., 3645.,  nan, 4292.,  nan])
```

*Ilustración 4. Principales errores presentados en la implementación de la librería Neurokit2, debidos a la incapacidad del algoritmo de detectar por completo los picos y dinámica de las señales.*

Además, las funciones de Neurokit2 emplean internamente operaciones que no se llegan a explorar en este trabajo, por lo que sus errores asociados no lograron ser resueltos, acarreado la decisión de eliminar algunas de las características que fueron propuestas. Sin embargo, se desarrolló el flujo completo de trabajo sobre una señal de ejemplo, demostrando que, con un análisis más robusto sobre la programación de estas rutinas, podrían ser evaluados por completo los datos de todos los sujetos.



*Ilustración 5. Gráfica de los valores de picos y valles detectados para una señal de ejemplo. Se puede apreciar que no todos los valles teóricos son localizados.*

## 7. Estructuras de red (3) y análisis de matrices de confusión.

**Clasificación con red neuronal MLP:** Se encontró en la literatura [11] un estudio en el que se quería clasificar señales ECG en normal y anormal, para ello fueron empleados diversos métodos de redes neuronales (MLP, BPN y FFN) con cantidades de neuronas diferentes. El estudio señala que la red que permitió obtener mejores resultados en cuanto a sensibilidad (100%), precisión y especificidad (100%) fue la MLP (perceptrón multicapa) con neuronas en la capa oculta con la siguiente distribución 20, 20, 10.

A partir de los resultados obtenidos con estos hiperparámetros se obtuvo la matriz de confusión de la ilustración 6. Posteriormente, se hicieron modificaciones arbitrarias de forma manual a los hiperparámetros, las cuáles fueron reducir el número de neuronas por capa (10 10 10), aumentar el valor de rata de aprendizaje (de 0.01 a 0.25), cambiar el algoritmo de optimización (lbfgs a adam) y realizar un entrenamiento epoch con un tamaño de batch de 500. Estos cambios se realizaron con el fin de identificar si la estructura mantiene sus resultados al ser más simple en su tamaño y si logra converger con un paso mayor iterando sobre todos los datos. La segunda estructura obtuvo una matriz de confusión que se presenta en la ilustración 7.




Ilustración 6. Matriz de confusión sin normalizar del modelo 1




Ilustración 7. Matriz de confusión sin normalizar del modelo 2

Finalmente, para la tercera estructura evaluada se realizó un GridSearch con el fin de encontrar los mejores hiperparámetros para el modelo MLP, los cuáles se expresan en la Tabla 1. Su matriz de confusión se presenta en la ilustración 8.




Ilustración 8. Matriz de confusión sin normalizar del modelo 3

Los hiperparámetros usados en los 3 modelos y las métricas obtenidas para cada evaluar la calidad y capacidad uno de ellos en la identificar señales de fibrilación auricular (AFIB) y ritmo sinusal (SB) se muestra en las tablas 1 y 2 respectivamente.

Tabla 1. Hiperparámetros empleados en cada modelo

	Modelo	hidden_layer_sizes	learning_rate_init	solver	batch_size
0	Modelo 1	20, 20, 10	0.01	lbfgs	-
1	Modelo 2	10, 10, 10	0.025	adam	500
2	Modelo 3	50, 50, 50	0.05	adam	200

Tabla 2. Métricas obtenidas para cada modelo evaluado

Modelo	Accuracy	Precisión AFIB	Precisión SB	Recall AFIB	Recall SB	F1 Score AFIB	F1 Score SB
1	0.9454	0.93	0.95	0.89	0.97	0.91	0.96
2	0.9298	0.95	0.92	0.83	0.98	0.88	0.95
3	0.9347	0.88	0.96	0.92	0.94	0.90	0.95



## Resultados y Análisis

Del proceso de extracción de características se puede concluir que la librería Neurokit2, aunque posee algoritmos y funciones con gran capacidad de reconocer los atributos de las señales ecg, para efecto de emplear estas herramientas en grandes conjuntos de datos se identifican limitantes, relacionadas principalmente con la capacidad de calcular características de manera uniforme en todos los registros. Además, se puede destacar que, al intentar calcular todas las métricas identificadas en un inicio, el coste computacional de este proceso fue considerablemente mayor (cerca de 3 veces).

Los resultados obtenidos después de evaluar los tres modelos muestran diferencias significativas entre ellos. El Modelo 1 clasificó correctamente 298 señales de AFIB y 673 de SB, con 35 falsos positivos (AFIB clasificados como SB) y 21 falsos negativos (SB clasificados como AFIB). Por otro lado, el Modelo 2 presentó una disminución en las clasificaciones correctas de AFIB, alcanzando solo 275, lo que incrementó los falsos positivos a 58. Sin embargo, este modelo mejoró ligeramente en el desempeño para SB, logrando 680 clasificaciones correctas. Finalmente, el Modelo 3 obtuvo el mayor número de predicciones correctas para AFIB, con un total de 307, aunque las clasificaciones correctas para SB se redujeron a 653.

La precisión global muestra diferencias ya que el Modelo 1 obtuvo el mejor desempeño con una precisión del 94.54%, seguido muy de cerca por el Modelo 3 con un 93.47%, mientras que el Modelo 2 mostró el menor rendimiento con una precisión de 92.98%.

Estas diferencias corresponden a los hiperparámetros utilizados en cada modelo. El Modelo 1 emplea una arquitectura moderada de capas ocultas (20, 20, 10), un *learning rate* inicial de 0.01 y el optimizador lbfgs (Limited-memory Broyden–Fletcher–Goldfarb–Shanno) con un máximo de 500 iteraciones. Con estos hiperparámetros tomados como referencia del artículo, se creó una línea base para establecer en el proceso de aprendizaje del modelo, con lo que, a partir de los resultados (favorables en términos generales) se establecieron los hiperparámetros de la siguiente arquitectura.

Entendiendo que: Accuracy indica el porcentaje total de predicciones correctas realizadas por el modelo sobre todas las muestras, Precisión mide la proporción de predicciones positivas (clasificadas como AFIB o SB) que son realmente correctas mediante la proporción de verdaderos positivos (TP) entre el total de positivos predichos (verdaderos positivos + falsos positivos), Recall (o Sensibilidad) mide la proporción de instancias positivas (AFIB o SB) que el modelo identificó correctamente mediante la proporción de verdaderos positivos entre el total de positivos reales (verdaderos positivos + falsos negativos), y F1-Score proporciona un equilibrio entre Precisión y Recall [12]. Se observa que efectivamente los hiperparámetros tomados del artículo de referencia son los que mejor accuracy presentan, seguidos del modelo 3 y por último el modelo 2, el cual tiene un recall superior para SB, lo que indica que es bueno para identificar todas las instancias de SB, pero su precisión es ligeramente menor, lo que sugiere que podría estar clasificando algunas muestras como SB cuando en realidad son AFIB. El modelo 3 tiene una precisión alta para SB, lo que indica pocos falsos positivos, pero su recall para AFIB es ligeramente menor, lo que sugiere que podría estar perdiendo algunas instancias de AFIB al tener más falsos negativos.

En términos generales, los modelos tienen desempeños cercanos, incluso el modelo 2 obtuvo los mejores valores de precisión AFIB y Recall SB, siendo el más simple, por lo que el conjunto de características seleccionado es lo suficientemente distintivo de cada patología para identificar patrones sin la necesidad de arquitecturas complejas, además, se podría abordar la posibilidad de realizar regularización a los modelos con el fin de evitar sobreentrenamiento y disminuir costes computacionales al reducir el número de iteraciones. De la misma forma, hay una diferencia de entre el 3 y el 7% en las métricas empleadas a favor de SB respecto a AFIB, por lo que los



datos parecen caracterizar mejor esta patología, probablemente debido a las características relacionadas con la frecuencia de las señales.

Por su parte, el Modelo 3, ajustado mediante GridSearch, utiliza una arquitectura más compleja (50, 50, 50) junto con el optimizador adam, sin embargo, este último cambio fue probablemente el que determinó que sus resultados, a pesar de la optimización de hiperparámetros, no fuesen considerablemente mejores de los modelos anteriores, siendo incluso menores en términos de accuracy, precisión en AFIB, recall SB y F1 Score. El optimizador lbfgs emplea una matriz de segundas derivadas de la función de pérdida, mientras que adam es de primer orden, utilizando gradiente estocástico descendente, con lo que, esta información adicional de concavidad al evaluar la función de coste pudo significar mejores ajustes a los parámetros durante el entrenamiento. Por último, todos los modelos presentaron convergencia y resultados superiores al 85% en las métricas evaluadas, por lo que incluso la tasa de aprendizaje (learning rate) más alta (0.05) fue suficiente para llegar a los mínimos de la función de coste, con lo cual es posible mejorar aún más las estructuras para reducir sus costes computacionales reduciendo también el número de iteraciones (que fue de 500 para todos los casos).

## 8. Consulta algoritmo de K means y máquinas de soporte vectorial.

### **K means**


Es un algoritmo de aprendizaje no supervisado usado con datos no etiquetados, es decir que los puntos de datos no tienen una estructura de clasificación definida, para su agrupación en clústeres (grupos) estipulando que un punto de datos puede existir en un solo clúster, a esto se le llama método de clustering exclusivo, estricto o “duro” [13].

Este es un algoritmo de agrupamiento basado en centroides. Este es un método de agrupación de clústeres que divide el conjunto de datos en grupos similares basado en la distancia entre sus centroides, en donde cada centroide de cada clúster es la media o la mediana de los puntos de este en función de los datos del clúster. En el caso del K means, el centro de cada clúster define este grupo utilizando una medida de distancia al centroide que normalmente es la distancia euclidiana. Los clústeres k óptimos son identificados por el algoritmo minimizando de forma iterativa la distancia total entre cada punto y el centroide del clúster al que fue asignado [13].


Este algoritmo, al tener un método de clustering exclusivo, funciona muy bien cuando los clústeres tienen tamaños similares y no hay valores atípicos ni cambios de densidad significativos en los datos debido a que es susceptible al sobreajuste al incluir datos atípicos [13].

El objetivo del K means es minimizar la suma de las distancias entre los puntos de los datos y el centroide de su clúster asignado. Un valor k (cantidad de clústeres) indica grupos más pequeños y con mayor detalle [13]. El algoritmo funciona de la siguiente manera:


- a) Luego de la elección del número de clústeres (k), se inicializan las coordenadas de los centroides de cada clúster en puntos aleatorios de los datos como se muestra en el ejemplo de la imagen [14]. C1 y C2 corresponden a los centroides.



- b) Los puntos son asignados a un clúster basado en la distancia de cada punto a cada centroide agrupándose con el más cercano [14].



- c) Luego de esto, el centroide de cada clúster es recalculado de tal manera que vuelva a ser el centro del grupo de datos [14].



- d) Los pasos b y c son repetidos hasta que es cumplido el criterio de parada estipulado para el algoritmo [14].

Existen tres criterios de parada:


- i. Cuando los centroides dejan de cambiar se asume que el algoritmo ha convergido [14].
- ii. Cuando los puntos dejan de cambiar de clúster se asume que el modelo está entrenado [14].
- iii. Cuando se cumple el límite de iteraciones estipulada por el programador pues se asume que luego de este valor el modelo no mejorará significativamente [14].

## SVM


Una máquina de soporte vectorial o SVM por sus siglas en inglés es un algoritmo de aprendizaje automático supervisado, es decir que sus datos se encuentran etiquetados, que es empleado en problemas de clasificación o de regresión y se desempeñan muy bien en conjuntos de datos con pocos valores atípicos [15].

Este algoritmo funciona por medio de la correlación de datos a un espacio de características en las que los datos puedan ser categorizados [16]. El algoritmo funciona de la siguiente manera:

- a) Primero se detecta un separador entre las categorías de los datos como se muestra en el ejemplo de la siguiente imagen [16]:




- b) Luego de la identificación de un separador, se realiza una transformación de los datos para que el separador encontrado se pueda extraer como un hiperplano como se muestra en la imagen [16].




Un hiperplano es una superficie de decisión que permite separar el espacio de los datos en dos partes siendo un clasificador binario. Estos hiperplanos no solo están limitados a un espacio de datos bidimensional sino a un espacio  $n$  dimensional en donde el hiperplano tendrá una dimensión  $n-1$  [15]. Este hiperplano es el límite de decisión en donde todos los datos de un lado serán clasificados de una manera y lo que caiga en el otro lado de otra forma (para el ejemplo de la imagen se clasifica como verde y rojo).


A hyperplane in  $\mathbb{R}^2$  is a line



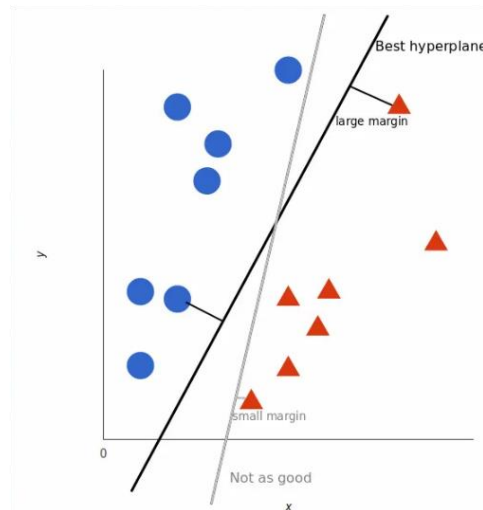
A hyperplane in  $\mathbb{R}^3$  is a plane




Para estas transformaciones es empleada una transformación matemática conocida como Kernel. Estos pretender realizar una separación lineal de los datos y a veces lo hacen aumentando la dimensión del espacio original en el que se encuentran los datos pues en su dimensión original no son linealmente separables [17]. Un ejemplo de esto se muestra en la siguiente imagen:



- c) Finalmente se debe seleccionar el mejor hiperplano para el modelo y este es el que maximiza los márgenes de los datos (distancia entre los datos y el hiperplano) para cada espacio de clasificación, es decir, el hiperplano óptimo es aquel cuya distancia al elemento más próximo de cada etiqueta o grupo de datos es la mayor [17].
- d)




Los ejemplos de aplicación se encuentran en el código anexo, a partir de ellos se obtuvo para el KMeans el gráfico presentado en la ilustración 9. Como se observa en la figura, solo se muestra un centroide, pero el algoritmo fue definido para 2 clústeres por lo que debería haber 2 centroides; esto indica que ambos centroides son los mismos para las dos clasificaciones (AFIB y SB), por lo que la distinción de ambas patologías empleando este algoritmo no fue posible, se considera que algunas de las características son similares entre los grupos, por lo que aportan a que la distribución de los mismos no sea agrupada, además, k-means agrupa de manera esférica, y dado que calcula distancias, en general no es bueno para clasificar comportamientos no lineales, por lo cual, es muy probable que con las características dadas este método no sea lo suficientemente robusto.



*Ilustración 9. Gráfico obtenido con los datos usando KMeans*

El resultado de la implementación del algoritmo SVM se muestra en la ilustración 10. En este gráfico, es evidente la separación por un hiperplano que divide el espacio en las secciones morada (AFIB) y amarilla (SB). A pesar de ello, se observan muchos datos, tanto morados como amarillos se encuentran fuera de su espacio de clasificación. Esto puede deberse a que no todas las características de todas las señales tienen una diferencia marcada, por lo que algunas logran clasificarse correctamente y otras no. Por otro lado, el hiperplano calculado, al ser de dimensión 2, no logra capturar todas las dinámicas presentes en los datos. En un análisis mayor, en el cuál pueda ser representada cada característica, seguramente se generen hiperplanos de mayor dimensión. Otra posible solución sería subdividir las características según sus comportamientos (lineal o no lineal) para así encontrar mediante SVM los hiperplanos correspondientes a cada subgrupo de características, y posteriormente, relacionar los resultados totales de clasificación. Sin embargo, SVM muestra resultados más prometedores que K-means, al tener puntos extremos más definidos en la clasificación encontrada.



*Ilustración 10. Gráfico obtenido con los datos usando SVM*

9. Consulta y análisis de equipos (3) comerciales que apliquen el uso de algoritmos de ayuda diagnóstica a partir de señales EKG y discutir brevemente las funcionalidades desde la teoría vista en el curso.

### **Philips PageWriter TC**

Los electrocardiógrafos Philips PageWriter (TC30, TC50, TC70) incorporan algoritmos avanzados para el análisis de señales ECG, diseñados para mejorar el flujo de trabajo y ofrecer informes diagnósticos rápidos y confiables en entornos clínicos. Estos dispositivos cuentan con el algoritmo ECG DXL de 16 contactos, desarrollado por Philips, que emplea métodos analíticos sofisticados para interpretar el ECG en reposo. Gracias al análisis de 16 contactos, permite obtener una interpretación completa del pecho de un adulto [18].

El algoritmo de ECG de 16 derivaciones Philips DXL ofrece interpretaciones líderes en la industria, junto con un conjunto de herramientas avanzadas para diagnóstico, que incluye la interpretación del ritmo y la morfología en una amplia variedad de poblaciones de pacientes. Además, integra valores críticos e identificación de la arteria culpable [19].

También incluye mapas ST, una herramienta diagnóstica que visualiza los cambios en el segmento ST, permitiendo detectar alteraciones en la actividad eléctrica del corazón, como las que ocurren en un infarto de miocardio. Este algoritmo también cuenta con un programa de identificación de errores, que puede detectar artefactos durante el proceso de toma de la señal, asegurando la precisión del diagnóstico [19].

### **MAC 2000**

El equipo MAC 2000 de la empresa GE Healthcare, es un electrocardiógrafo diseñado para adquisición, análisis, registro y transmisión de ECK de 12 derivaciones [20]. Este equipo ofrece portabilidad pues cuenta con una batería que le autonomía continua por 2 horas que son equivalentes a 250 informes de un paciente estándar, brinda información precisa y fiable para la obtención de diagnósticos más rápidos y la posibilidad de almacenarlos y enviarlos de forma rápida y fácil, además de permitir una visualización del ECG antes de imprimirlo [20].

Este equipo implementa el programa de análisis Marquette 12SL desarrollado por la misma empresa el cual brinda un informe diagnóstico para facilitar la toma de decisiones médicas minimizando el tiempo dedicado a leer ECG en exceso, además, este sistema ofrece un conjunto completo de herramientas para el análisis del ECG fiables gracias a que han sido rigurosamente comparadas con amplias bases de datos [21].

Algunas de las características del algoritmo del programa Marquette 12SL son:

- Aumento de sensibilidad automático: esta herramienta aumenta la sensibilidad para el infarto agudo de miocardio con elevación del segmento ST o la isquemia aguda en pacientes con sospecha de tener un evento cardíaco de gravedad ponderando el hallazgo de elevación del segmento ST ya que este es un indicador relevante y específico en síndrome coronario agudo (SCA) [22].
- Apoyo a la toma de decisión por medio de comparación serial: el programa indica los cambios que presenta el ECG del paciente respecto al ECG anterior del mismo paciente mediante comparaciones de formas de onda y de mediciones del ECG para maximizar la precisión en la detección de cambios que sean clínicamente significativos [22].
- Exactitud: la identificación del intervalo QT prolongado es relevante pues esta alteración puede provocar una arritmia grave e incluso muerte súbita cardíaca, pero, la medición de este intervalo con precisión puede verse afectada por factores como el ruido y la dificultad de definir el final de la onda T, pero este programa mide el intervalo QT a partir de un complejo medio que permite reducir la influencia del ruido [22].
- Declaraciones de ritmo: permite la detección de marcapasos ventriculares mediante la identificación del ritmo subyacente [22].

- Especificidad: el programa permite una detección de eventos haciendo una interpretación de estos de acuerdo con la edad y al género del paciente [22].

## Reveal LINQ™

Es un monitor cardíaco insertable equipado con los algoritmos de inteligencia artificial AccuRhythm, diseñado especialmente para pacientes que experimentan síntomas poco frecuentes y necesitan monitoreo a largo plazo. El dispositivo tiene un tamaño comparable al de una batería AAA, y su procedimiento de inserción es mínimamente invasivo. AccuRhythm fue entrenado y desarrollado con más de un millón de ECG evaluados profesionalmente, con el objetivo de preservar la sensibilidad y proporcionar análisis basados en datos libres de sesgos. Esto contribuye a reducir las alertas falsas relacionadas con la presencia de fibrilación auricular, ofreciendo resultados más confiables para el manejo clínico [23].

Reveal LINQ™ está diseñado para detectar y monitorear de manera continua y remota problemas cardíacos como arritmias, síncope, fibrilación auricular y otros eventos infrecuentes que son difíciles de identificar con métodos tradicionales como los holter o electrocardiogramas estándar. Su batería tiene una duración de hasta tres años, y su tamaño compacto facilita la inserción subcutánea mediante una incisión mínima de aproximadamente 1 cm. Además, cuenta con conectividad remota a través del sistema Medtronic CareLink Network, que permite transmitir datos automáticamente para que los médicos puedan acceder a información en tiempo real o en intervalos programados, reduciendo la necesidad de visitas frecuentes al consultorio. También contribuye a la evaluación de la necesidad de anticoagulación en casos de fibrilación auricular y a la identificación de causas cardíacas en pacientes con síncope recurrente [24].

Tanto el Philips PageWriter TC como el MAC 2000 realizan el proceso de captación de la señal ECG, la cual contiene ruido por la presencia de diversos artefactos que deben ser procesados para realizar un buen análisis de la señal y, por tanto, se podría decir que realizan procesos de filtrados para mejorar la calidad de la señal y realizar una correcta extracción de las características que realmente son de interés para el diagnóstico.

Además de esto, dado que los tres dispositivos mencionados anteriormente implementan algoritmos para el diagnóstico, previo a su comercialización se debieron realizar múltiples procesos de entrenamiento con bases de datos amplias para la identificación de anomalías en las señales que puedan conducir al diagnóstico de ciertas patologías. Si bien los fabricantes no revelan los algoritmos implementados, seguramente se implementan transformaciones de los datos para la extracción de características y así poderlos clasificar e incluso predecir.

## REFERENCIAS

- [1] «Optimal Multi-Stage Arrhythmia Classification Approach | Scientific Reports». Accedido: 30 de noviembre de 2024. [En línea]. Disponible en: <https://www.nature.com/articles/s41598-020-59821-7>
- [2] Victoria Eugenia Montes R,<sup>1</sup> Gustavo A. Guarín,<sup>2</sup> Germán Castellanos Domínguez<sup>3</sup>, «Extracción de características de ECG basadas en transformaciones no lineales y wavelets». 2005. [En línea]. Disponible en: <https://repositorio.unal.edu.co/bitstream/handle/unal/28699/14661-57060-1-PB.pdf?sequence=1>
- [3] T. Pham, Z. J. Lau, S. H. A. Chen, y D. Makowski, «Heart Rate Variability in Psychology: A Review of HRV Indices and an Analysis Tutorial», *Sensors*, vol. 21, n.º 12, p. 3998, jun. 2021, doi: 10.3390/s21123998.
- [4] M. Navaneethakrishna y S. R. Manuskandan, «Analysis of Heart Rate Variability in Normal and Diabetic ECG signals using Fragmentation Approach», *Annu. Int. Conf. IEEE Eng. Med. Biol. Soc. IEEE Eng. Med. Biol. Soc. Annu. Int. Conf.*, vol. 2021, pp. 1112-1115, nov. 2021, doi: 10.1109/EMBC46164.2021.9631076.
- [5] «Ondas del Electrocardiograma». Accedido: 30 de noviembre de 2024. [En línea]. Disponible en: <https://www.my-ekg.com/generalidades-ekg/ondas-electrocardiograma.html?form=MG0AV3>
- [6] «Validity of P-peak to R-peak interval compared to classical PR-interval to assess dynamic beat-to-beat AV conduction variability on surface electrocardiogram - IOPscience». Accedido: 30 de noviembre de 2024. [En línea]. Disponible en: <https://iopscience.iop.org/article/10.1088/2057-1976/aab814/meta>
- [7] «Example of ECG feature points, onset points and offset points. | Download Scientific Diagram». Accedido: 30 de noviembre de 2024. [En línea].



- Disponible en:  
[https://www.researchgate.net/figure/Example-of-ECG-feature-points-onset-points-and-offset-points\\_fig7\\_322752368](https://www.researchgate.net/figure/Example-of-ECG-feature-points-onset-points-and-offset-points_fig7_322752368)
- [8] «ECG Rate Interpretation • LITFL Medical Blog • ECG Library Basics». Accedido: 30 de noviembre de 2024. [En línea]. Disponible en: <https://litfl.com/ecg-rate-interpretation/>
- [9] R. D. C. Granados, «ENTROPÍA APROXIMADA Y MUESTRAL DE LA VARIABILIDAD DE LA FRECUENCIA CARDÍACA EN ELECTROCARDIOGRAMAS CORTOS Y LARGOS DE HOMBRES JÓVENES».
- [10] P. Martinez, A. Rey, y W. Legnani, «Clasificación de señales de ECG arrítmicas en el espacio de características entropía-complejidad-tiempo de retraso de embebido», *Proyecciones*, vol. 20, p. 2022, nov. 2022.
- [11] H. M. Rai, A. Trivedi, y S. Shukla, «ECG signal processing for abnormalities detection using multi-resolution wavelet transform and Artificial Neural Network classifier», *Measurement*, vol. 46, n.º 9, pp. 3238-3246, nov. 2013, doi: 10.1016/j.measurement.2013.05.021.
- [12] «What is Accuracy, Precision, Recall and F1 Score?». Accedido: 1 de diciembre de 2024. [En línea]. Disponible en: <https://www.labelf.ai/blog/what-is-accuracy-precision-recall-and-f1-score>
- [13] «¿Qué es el agrupamiento de medias k? | IBM». Accedido: 30 de noviembre de 2024. [En línea]. Disponible en: <https://www.ibm.com/mx-es/topics/k-means-clustering>
- [14] F. Sanz, «Algoritmo K-Means - Clustering y cómo funciona», *The Machine Learners*. Accedido: 30 de noviembre de 2024. [En línea]. Disponible en: <https://www.themachinelearners.com/k-means/>
- [15] C. C. Rodriguez, «Maquina de Soporte Vectorial (SVM)», *Medium*. Accedido: 30 de noviembre de 2024. [En línea]. Disponible en: <https://medium.com/@csarchiquerodriguez/maquina-de-soporte-vectorial-svm-92e9f1b1b1ac>
- [16] «SPSS Modeler Subscription». Accedido: 30 de noviembre de 2024. [En línea]. Disponible en: <https://www.ibm.com/docs/es/spss-modeler/saas?topic=models-about-svm>
- [17] S. Navarro, «Importancia de los Kernels para los SVM». Accedido: 30 de noviembre de 2024. [En línea]. Disponible en: <https://keepcoding.io/blog/importancia-de-los-kernels-para-los-svm/>
- [18] «Ver detalles del Philips Algoritmo ECG DXL de 16 contactos», Philips. Accedido: 30 de noviembre de 2024. [En línea]. Disponible en: <https://www.philips.es/healthcare/product/HCNOCTN68/algoritmo-ecg-dxl-de-16-contactos-algoritmo-ecg>
- [19] «Ver detalles de Philips Cardiografos PageWriter TC30». Accedido: 30 de noviembre de 2024. [En línea]. Disponible en: <https://www.philips.com.co/healthcare/product/HC860306/cardiografos-pagewriter-tc30-cardigrafo>
- [20] «Electrocardiografo - MAC 2000 - GE - PV Equip». Accedido: 30 de noviembre de 2024. [En línea]. Disponible en: <https://pvequip.cl/producto/electrocardiografo-mac-2000-ge/>
- [21] GE Healthcare, «Sistema de análisis de ECG MAC 2000 Optimizado para su centro sanitario.» [En línea]. Disponible en: <https://matclinic.com/wp-content/uploads/2022/08/Catalogo-MAC-2000.pdf>
- [22] «Marquette 12SL ECG Analysis Programs | GE HealthCare (United States)». Accedido: 30 de noviembre de 2024. [En línea]. Disponible en: [https://www.gehealthcare.com/products/marquette-12sl?srsId=AfmBOoqkKPbNlr-QcXT7OW0tMkovbA5J7CX18XxeFfcSe2iMB0q4RjJ\\_](https://www.gehealthcare.com/products/marquette-12sl?srsId=AfmBOoqkKPbNlr-QcXT7OW0tMkovbA5J7CX18XxeFfcSe2iMB0q4RjJ_)
- [23] «Reveal LINQ ICM System - Cardiac Monitors | Medtronic». Accedido: 30 de noviembre de 2024. [En línea]. Disponible en: <https://europe.medtronic.com/xd-en/healthcare-professionals/products/cardiac-rhythm/cardiac-monitors/reveal-linq-icm.html#accrhythm-ai-algorithms>
- [24] Medtronic, «El sistema Reveal LINQ™». 2015. [En línea]. Disponible en: <https://asiapac.medtronic.com/content/dam/medtronic-com/us-en/hcp/diagnostics/documents/patient-ed/reveal-linq-patient-introduction-brochure-spanish-201602395sl.pdf>